Miguel Ozana

Engenheiro de Dados | Python · PySpark · SQL · Cloud

Rio de Janeiro, RJ · miguelsilva2004jpa@gmail.com · (21) 98631-8960
linkedin.com/in/miguel-ozana-951855231 · github.com/m1guelozana · miguelportfolio-plum.vercel.app

RESUMO

Engenheiro de dados no Serpro, atuando com Spark, Cloudera (Hive/Impala) e Microsoft Azure. Desenvolve pipelines e validações em PySpark sobre Delta Lake e Parquet (arquitetura Medalhão), integra APIs REST, orquestra fluxos com Airflow e opera rotinas em produção com Kerberos, cron e logging estruturado. Experiência prévia em automações e web scraping com Python e Selenium. Inglês avançado/fluente.

COMPETÊNCIAS TÉCNICAS

Engenharia de dados	PySpark, Apache Spark, Pandas, Openpyxl, Delta Lake, Parquet, ETL/ELT, Arquitetura Medalhão, Ibis, validação e qualidade de dados
Nuvem e plataformas	Microsoft Azure (Azure Data Lake), AWS (S3, boto3), Databricks, Cloudera (Hive/Impala), Docker
Orquestração	Apache Airflow, cron, shell script
Linguagens e bancos	Python, SQL (Impala, Hive, PostgreSQL), NoSQL, Java, TypeScript
Back-end e front-end	FastAPI, Flask, Django, React, Streamlit
Automação e coleta	Selenium, BeautifulSoup (BS4), web crawlers/scrapers, requests
Ferramentas	Git/GitHub, Metabase, Linux, Kerberos

EXPERIÊNCIA PROFISSIONAL

Desenvolvedor – Serpro
Nov/2024 – Presente

Engenharia de Dados

- **Pipeline de auditoria de queries Impala:** coleta via API REST do Cloudera Manager, com janela temporal parametrizável e retry; deduplicação por `queryId`, schema explícito (`StructType`) em PySpark e carga em tabela Hive/Impala particionada (DDL via Ibis).
- **Produtização e operação:** notebook Jupyter convertido em script PySpark (`spark-submit`) com argparse, logging e configuração via `config.json`; execução recorrente com Kerberos, lock file e cron a cada 15 minutos.
- **Comparador e validador de tabelas entre data lakes (Azure e SAS):** projeto em PySpark no ambiente Microsoft Azure, com Delta Lake/Parquet, checagens de consistência e relatórios de validação em Excel.
- **Dashboard de monitoramento (em desenvolvimento):** FastAPI e React para configuração do pipeline e consulta de logs.

Desenvolvedor – Miceli Sociedade de Advogados
Ago/2023 – Ago/2024

Automações jurídicas

- Automações em Python e Selenium para acompanhamento e confirmação de processos (Benner, eLaw) e scraper de intimações, eliminando conferência manual.
- Chatbot para WhatsApp em TypeScript.

PROJETOS DE ENGENHARIA DE DADOS

PIB Municipal Data Pipeline – Arquitetura Medalhão
Abr/2025

Apache Spark, Airflow (SparkSubmitOperator) e Delta Lake nas camadas bronze, silver e gold; Parquet, Docker e visualização com Metabase.

ETL Pipeline – Bronze to Gold
Fev/2025

ETL em Python: limpeza e transformação de dados brutos da camada bronze, gravados em Parquet no data lake.

Orquestração de Pipelines com Apache Airflow
Mar/2025

Automação e agendamento de fluxos ETL com Apache Airflow.

Pipeline ELT com PokéAPI
Em desenvolvimento

Ingestão em Python (requests e boto3) com gravação de JSON na camada raw de um bucket AWS S3, seguida de carga e transformação.

FORMAÇÃO E VOLUNTARIADO

Bacharelado em Engenharia de Software – UniBTA — Ago/2024 – Dez/2028 (previsão)

Tecnólogo em Análise e Desenvolvimento de Sistemas – IBMR — Jan/2023 – Ago/2025

Técnico em Programação e Design de Jogos Digitais – FIRJAN SENAI SESI — Jan/2020 – Dez/2022

Equipes de robótica no ensino técnico; jurado voluntário em torneios FIRST (FTC, FRC, FLL) e TBR.